Monitor de papers no arXiv

Relatório técnico | Lilian Morais Brum
Desafio de Automação de Processos - Unidade EMBRAPII DCC-UFMG

1. Objetivo e abordagem

A PoC monitora candidatos no arXiv e identifica evidências de Engenharia de Software e Sistemas Inteligentes em título e resumo. Python 3.14 e sua biblioteca padrão realizam coleta, classificação, armazenamento e geração de relatório, sem credenciais de serviços de IA ou dependências externas obrigatórias.

A consulta usa cs.SE ou as expressões “software engineering”, “program repair” e “code generation”, retornando até 100 candidatos ordenados pela data de submissão. A API fornece XML/Atom; o coletor extrai identificador, título, autores, resumo, datas, categorias e link.

2. Componentes e fluxo de dados

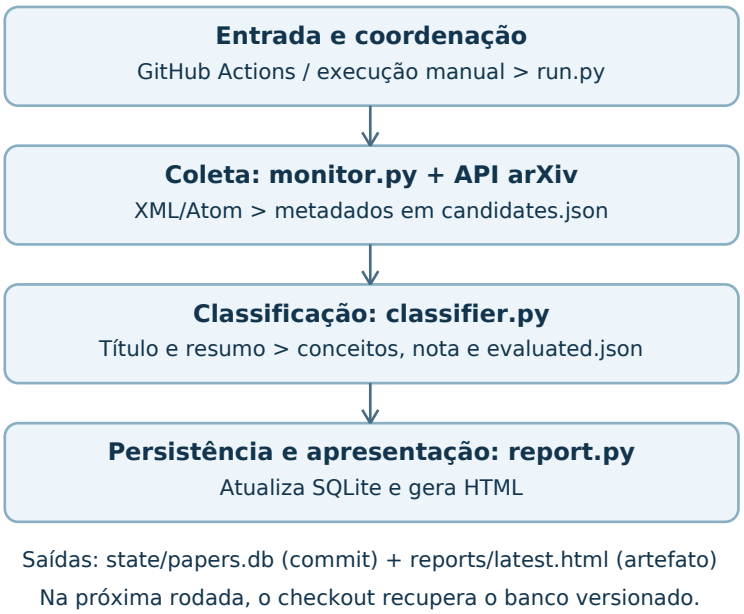


Figura 1. Arquitetura implementada, da entrada agendada às saídas persistidas. O coordenador interrompe as etapas seguintes quando um processo retorna erro; um relatório anterior pode permanecer em disco e deve ser identificado pela data de geração.

3. Seleção explicável e pontuação

O classificador normaliza caixa, espaços e hífens e procura expressões com limites de palavras. Variantes como LLM, LLMs e large language models pertencem ao mesmo conceito. A inclusão exige pelo menos um conceito de cada tema; a justificativa informa os conceitos e o JSON conserva as expressões encontradas e a versão do classificador.

Sem evidências, a nota é 0; com evidências de apenas um tema, é 1 ou 2 e o artigo é excluído. Para selecionados: **nota = 3 + min(2, número de conceitos distintos - 2)**. A escala indica cobertura lexical temática, sem representar qualidade científica, probabilidade ou confirmação semântica.

4. Armazenamento, relatório e automação

SQLite armazena todos os candidatos avaliados. A chave é o identificador arXiv sem o sufixo de versão: novas versões atualizam o registro existente. São mantidos metadados e avaliação em JSON, nota, indicador de seleção e datas da primeira e da última detecção em UTC. O banco versionado inclui a base inicial da demonstração.

“Visto pela primeira vez” significa ausente do banco antes da rodada; não significa publicado naquele dia. Um artigo já conhecido que passa a ser selecionado não incrementa esse contador. O HTML apresenta os selecionados da consulta atual, seus metadados, resumo, nota e justificativa. Os textos externos são escapados antes da inclusão no HTML.

GitHub Actions executa testes e monitor diariamente às 12h17 UTC (09h17 em UTC-3), além de permitir disparo manual. O banco em state/papers.db é preservado por commit na main com a permissão contents: write. HTML e avaliações são publicados como artefato com retenção de 30 dias. A concorrência do workflow é serializada; alterações externas na branch ainda podem causar conflito de push.

5. Decisões de implementação

Biblioteca padrão: reduz instalação e facilita a execução multiplataforma. **Regras por conceitos:** oferecem rastreabilidade, reprodutibilidade e custo previsível, em troca de menor compreensão contextual. **SQLite:** simplifica a persistência e a deduplicação. **HTML:** permite consulta no navegador sem servidor. **Actions:** executa sem depender de um computador pessoal ligado. Versionar o banco é uma escolha de simplicidade para esta PoC, com custo de crescimento do histórico Git.

6. Validação observada

A candidata confirmou seis testes unitários aprovados: exigência dos dois temas, inclusão de exemplo combinado, aliases sem nota duplicada, normalização de hífen, rejeição de exemplo não relacionado e teto de cinco pontos. Na execução local observada, 100 candidatos resultaram em 24 selecionados. Duas gravações consecutivas mantiveram 100 registros e reduziram o contador de selecionados inéditos de 24 para 0.

Uma execução manual do workflow em Linux foi confirmada como bem-sucedida pela candidata, que também baixou e abriu o HTML. Windows foi utilizado localmente; macOS não foi testado diretamente. Esses resultados verificam funcionamento, mas não medem precisão ou cobertura em uma amostra rotulada. Uma rodada agendada ainda não foi confirmada nesta validação.

7. Limitações e próximos passos

A consulta é limitada aos 100 candidatos mais recentes, sem paginação ou recuperação de intervalos perdidos; portanto, pode omitir artigos entre rodadas. As regras em inglês podem perder sinônimos, ignorar negações e selecionar mera coocorrência dos temas. Não há retentativa automática em falhas de rede, envio de e-mail nem avaliação semântica. A agenda depende da disponibilidade do GitHub e pode atrasar.

Evoluções prioritárias: paginação com janela temporal e sobreposição, retentativas com espera, avaliação de precisão e cobertura em amostra revisada, comparação com classificador semântico e migração do estado para armazenamento externo.

Referências: arXiv API User’s Manual: https://info.arxiv.org/help/api/user-manual.html
Código: https://github.com/Lilianbrum/poc-is